

**«Национальный исследовательский Нижегородский государственный  
университет им. Н.И. Лобачевского»**



Институт информационных технологий, математики и механики

Кафедра: Математическое обеспечение и суперкомпьютерные технологии

**Выпускная квалификационная работа бакалавра**

**Исследование возможностей объяснимого искусственного  
интеллекта в задаче ранней диагностики стресса растений**

**Выполнила:**

студентка гр. 381706-1

Максимова И. И.

**Научный руководитель:**

проф. каф. МОСТ, д-р техн. наук

Турлапов В.Е.

Нижний Новгород, 21 июня 2021

## Сбор информации:


- Беспилотные летательные аппараты
- Датчики на с/х транспортных средствах

## Методы диагностики:

- Алгоритмы машинного обучения
- Нейронные сети

## Проблемы:

- Сложность обработки ошибок
- Необъяснимость решений



**Цель:** Создание простых XAI-блоков для ранней диагностики стрессовых состояний растений

## Два этапа:

- I. Поиск эффективных моделей МО для ранней диагностики стресса растений
- II. Создание XAI-блока на базе самой эффективной модели

Инструменты исследования:



scikit-image  
image processing in python



PyTorch

# 1. Поиск эффективных моделей МО

## Описание датасета и признаков

Обзор возможностей методов МО проводился на примере задачи классификации болезней листьев томатов.

### Признаки:

- STAT - {mean, std, min, max};
- HIST - бины квантованной гистограммы
- GLCM - текстурные признаки
- ALL = STAT + HIST + GLCM

### Способ извлечения признаков:


- Локальный (17x17)
- Глобальный

### «Источники» признаков:


- Изображения в красном канале
- NDVI<sub>G</sub> образы:

$$NDVI_G = \frac{GREEN - RED}{GREEN + RED}$$


### PlantVillage (6K изображений)



Примеры изображений 6-ти классов больных листьев томатов



Изображение листа, больного Bacterial Spot в RGB, Red и NDVI<sub>G</sub> каналах




Отражение хлорофиллом разных длин волн


# 1. Поиск эффективных моделей МО

## Результаты классификации

### Классификация на RED признаках



### Классификация на NDVI<sub>G</sub> признаках



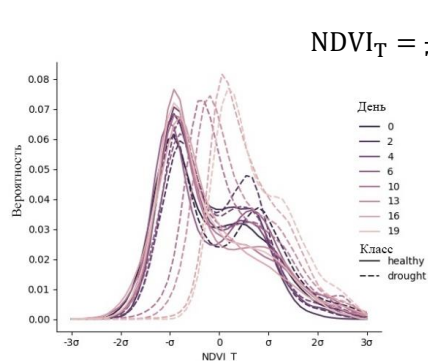

DT - Дерево решений  
KNN - К-ближайших соседей  
RF - Случайный лес

LDF - Линейный дискриминант Фишера  
SVM - Мультиклассовый метод опорных векторов  
SLP - Одноуровневый перцептрон

## 2. Создание XAI-блока Прикладная задача и SLP-решение


- Задачи **ранней диагностики засухи у растений пшеницы**, регистрируемой сенсорами двух типов (тепловым TIR и RGB): детектирование стресса и прогнозирование продолжительности стресса.
- В качестве исходных данных использованы две группы изображений в градациях серого NDVI (нормализованный разностный индекс растительности): на основе **Thermal IR**; на основе **RGB**.
- **Классификатор SLP** и **регрессор SLP** используются в качестве инструментов для анализа эффективности признаков стресса. SLP-модели анализируются и оптимизируются как XAI-модели.

Низкое разрешение TIR




**NDVI<sub>T</sub>** Изменение гистограммы здоровых и засушливых растений за период эксперимента

$$NDVI_T = \frac{TIR - RED}{TIR + RED}$$




**NDVI<sub>T</sub>** образец

$$NDVI_G = \frac{GREEN - RED}{GREEN + RED}$$



**NDVI<sub>G</sub>** Изменение гистограммы здоровых и засушливых растений за период эксперимента



**NDVI<sub>G</sub>** образец


Высокое разрешение RGB

## **Направления в ХАI, взятые для исследования проблемы ранней диагностики стресса растений**


1. **Использование классических методов машинного обучения и методов глубокого обучения для решения прикладных задач**
2. **Интерпретация узлов сети как семантических понятий**
3. **Использование методов глубокого обучения в ХАI.**
  - а. **Визуализация внутренних нейронов**
  - в. **Комплексное упрощение сети**
  - с. **Контрастирование узлов сети как семантических понятий**
4. **Быстрая неитеративная коррекция ошибок**

# Комплексное упрощение сети и интерактивность

- **Простая базовая структура.** В качестве простой базовой структуры был выбран **однослойный перцептрон  $SLP(N)$**  с произвольным числом нейронов  $N$  на скрытом слое. Использованы две его модели: классификатор  $SLP_C(N)$  и регрессор  $SLP_R(N)$ .
- Для достижения **интерактивности** обучение на изображениях заменено обучением на векторах признаков изображений. Это позволило сократить время обучения классификатора **до долей секунды**, а для регрессора - **до единиц секунд**. → **Быстрое обучение, оптимизация, быстрая коррекция ошибок.**
- **Узлы  $SLP$  как семантически понятия.** Вектор признаков включает в себя результаты типовой и специальной обработки изображений. Типовая обработка представлена двумя группами признаков: **STAT** {mean, std, min, max}; **HIST** - значения квантованной гистограммы. Специальная - группой **GLCM** (gray-level co-occurrence matrix), формализующей текстурные признаки. → **Узлы как понятия**




Архитектура  $SLP_C(N)$  для детектирования стрессовых состояний пшеницы




Архитектура  $SLP_R(N)$  для предсказания дня засухи пшеницы

### Анализ весов SLP(N)-классификатора засухи


- Вектор признаков включает в себя результаты типовой и специальной обработки изображений.
- Типовая обработка представлена двумя группами признаков: STAT {mean, std, min, max}; HIST - значения квантованной гистограммы. → **Узлы как общие понятия**
- Специальная - группой GLCM, формализующей текстурные признаки. → **Узлы как специальные понятия**
- **Визуализация весов.** SLP-модели оснащены инструментами для анализа и визуализации весов компонентов вектора признаков.



Анализ влияния  
всех 3-х групп



Анализ влияния группы GLCM-признаков  
для 4 углов при расстоянии = 1



NDVI-изображения. Индивидуальные веса для каждого элемента вектора признаков засухи, полученные после обучения SLP<sub>c</sub>(3)-классификатора засухи. Вектор признаков включает 5 скаляров на основе GLCM (контраст, однородность, энергия, корреляция, энтропия) для каждого из 4 углов поворота.



## Визуализация внутренних нейронов (2)



Анализ точности  $SLP_C(N)$ -классификатора засухи (в терминах F-score)

- SLP-узлы, представляющие общие понятия (как понятие группы или как понятие отдельного признака): **STAT, HIST**
- SLP-узлы, представляющие специальные понятия (как понятие группы или как понятие отдельного признака): **GLCM**
- **Визуализация.** SLP-модели оснащены инструментами для анализа и визуализации эффективности компонентов вектора признаков. SLP-модели можно исследовать и оптимизировать по группам признаков → **неитеративное упрощение структуры систем после обучения**

**Результаты упрощения  $SLP_C(N)$  при фиксированном квантовании ( $L=4$ ):**

**NDVI<sub>T</sub> данные.**  $N=2$ , для любой группы признаков, абсолютный max F-score=1.

**NDVI<sub>G</sub> данные.**  $N=1$ , для GLCM (специальных) и ALL (полная группа) признаков, абсолютный max F-score=0.9



Эффективность всех групп признаков: STAT, STAT+HIST, GLCM, ALL для  $SLP_C(N)$  при числе уровней квантования  $L=4$  для NDVI<sub>T</sub> и NDVI<sub>G</sub>

## Визуализация внутренних нейронов (3)

Анализ точности  $SLP_R(N)$ -регрессора (в терминах RMSE дня засухи)

- **Визуализация и анализ.** SLP-модели оснащены инструментами для анализа и визуализации эффективности компонентов вектора признаков → **неитеративное упрощение структуры систем после обучения**



**Анализ.** Анализируя поведение кривой ALL в сравнении с STAT+HIST и GLCM можно увидеть, что концептуальные группы признаков, STAT+HIST и GLCM, работают как антагонисты.

**Результаты упрощения  $SLP_R(N)$  при фиксированном квантовании ( $L=4$ ):**

**NDVI<sub>T</sub> данные.**  $N=3$ , STAT+HIST,  $RMSE=0.8$ .

Абсолютный min  $RMSE=0.67$  для  $N=27$ , STAT+HIST.

**NDVI<sub>G</sub> данные.**  $N=2$ , ALL, абсолютным min  $RMSE=3$ .



Эффективность всех групп признаков: STAT, STAT+HIST, GLCM, ALL для  $SLP_R(N)$  при числе уровней квантования  $L=4$  для NDVI<sub>T</sub> и NDVI<sub>G</sub>

## 2. Создание XAI-блока

# Упрощение структуры SLP-регрессора в ходе обучения при оптимизации точности (1)

- Упрощения структуры SLP-регрессора при оптимизации точности осуществляется за счет вариативности числа уровней квантования ( $L$ ), которое формирует признаки: бины гистограммы и уровни серого для GLCM.
- Используются две схемы квантования, ориентированные на свойства наборов данных после их нормализации.




Схема 1 (для  $NDVI_T$ )


Число уровней ( $L$ )	Границы квантования( $\sigma$ )
4	(-2, -1, 0, 1, 2)
6	(-2, -1, -0.5, 0, 0.5, 1, 2)
8	(-2, -1.5, -1, -0.5, 0, 0.5, 1, 1.5, 2)
10	(-2, -1.5, -1, -0.5, -0.25, 0, 0.25, 0.5, 1, 1.5, 2)

Результаты упрощения  $SLP_R(N)$  с применением схемы 1:


$NDVI_T$  данные.  $N=3$  при  $L=10$ , STAT+ HIST (типовые), абсолютный min RMSE=0.617

$NDVI_G$  данные.  $N=1$ , при  $L=10$ , GLCM (специальные), абсолютный min RMSE=2.83

$NDVI_T$



$NDVI_G$



Эффективность всех групп признаков: STAT, STAT+HIST, GLCM, ALL для  $SLP_R(N)$  при разном способе квантования  $L$  (схема 1) для  $NDVI_T$  и  $NDVI_G$

1. Всесторонне решена проблема диагностики ранней засухи растений с помощью **простых моделей однослойного перцептрона (SLP)**.
2. Специальные интерактивные **SLP-классификатор** и **SLP-регрессор**: построены и оснащены инструментами XAI.
3. **Изображения датасета** заменены на **векторы признаков**, состоящие из групп STAT, HIST и GLCM.
4. SLP-узлы интерпретированы как **семантические понятия** в терминах групп признаков:
  - а. **STAT; HIST** - как **общие понятия** SLP-узлов (как группа в целом, так и отдельные признаки)
  - в. **GLCM** - как **специальные понятия** SLP-узлов (как группа в целом, так и отдельные признаки)
5. Для **SLP-классификатора** и **SLP-регрессора**, как XAI моделей, были реализованы:
  - а. **Визуализация внутренних нейронов** после обучения (веса и точность для каждого количества нейронов)
  - в. **Комплексное упрощение сети** (по количеству нейронов и семантическим концепциям)
  - с. **Контрастирование узлов SLP как семантических концепций** (и через уменьшение интервала квантования HIST)
6. **Использование таких оптимизированных SLP-моделей возможно для быстрой неитеративной коррекции ошибок**
7. **XAI-возможности SLP-моделей** исследованы и **эффективно использованы для решения проблемы ранней диагностики засухи растений**.